

Arama açılınca kim kazanıyor

Yapay zekâ asistanlarına marka listesi vermeden sorduk. Web araması kapalıyken modeller Mullvad ve IVPN öneriyor; arama açıldığında öneri NordVPN, ExpressVPN ve Surfshark'a kayıyor. Bu kayma iki ayrı korpusta, farklı modellerle, iki dilde ve iki sektörde aynı yönde çıktı.

9.586 İngilizce yanıt 300 Türkçe yanıt 282.450 aday çifti 5 domain M0-M3 model ailesi
74/74 test

BU KAYITTA NE VAR

1. [Bugün ne kuruldu](#)
2. [Kullanılan veri, model ve araçlar](#)
3. [Bulgu 1 · Aramanın yön değiştirdiği yer](#)
4. [Bulgu 2 · Model ailesi, beş domain](#)
5. [Bulgu 3 · Maskeleye ablation'ı](#)
6. [Bulgu 4 · Kararı ne sürüklüyor](#)
7. [Bugün düzeltilen yedi şey](#)
8. [Sınırlılıklar](#)
9. [Yöntem · sızıntı önlemleri](#)
10. [Yeniden üretme](#)
11. [Nerede kaldık](#)

YAPILAN İŞ

Bugün ne kuruldu

Sabah elimizde yalnız veri toplama hattı vardı. Gün sonunda modellemeye hazır veri, çalışan bir model ailesi ve üç ölçülmüş bulgu var. Kod iki dilde **aynı modülleri iki kez** çalıştırıyor; hiçbir yerde dile özel ayrı bir hat yok.

MODÜL	NE YAPIYOR
brands.py	İki dili tek marka anahtarında buluşturur. Toplama hattının Türkçe küçük harf kuralı <code>IVPN</code> 'i <code>ivpn</code> 'e çevirmişti; i-katlaması bunu geri alır. Küratörlü kayıtları yükler.
datasets.py	İngilizce düzleştirilmiş parquet ile Türkçe JSON dışa aktarımını tek yanıt şemasına indirir.
pairs.py	Her yanıtı (yanıt, aday marka) satırlarına açar. İki hedef, arama sonucu özellikleri, kaynak tipi etiketleme ve <code>[BRAND]</code> maskeleye burada.
features.py	Fold içi marka prior'ları ve snippet dil özellikleri. Cevaptan türeyen sızıntıyı sert kontrolle engeller.
splits.py	<code>query_id</code> bazlı gruplu fold'ları atar, diske dondurur, sızıntıyı denetler.
models.py	naive → M0 → M1 → M2 kümülatif ailesi, fold-dışı skorlama, üretim modeli yeniden eğitimi.
cross_encoder.py	M3 cross-encoder, maskeleye ablation'ı ve uzunluğa göre gruplu batch'leme.
evaluate.py	PR-AUC, top-1, NDCG@3, Brier ve sorgu kümesinde bootstrap güven aralıkları.

Küratörlü marka kaydı

Beş domain için YAML olarak yayında — kod değil, denetlenebilir veri. Protokoller (WireGuard, NordLynx), denetim firmaları (Deloitte, Cure53), yayınlar (PCMag, Wirecutter), ana şirketler (Unilever, LVMH) ve perakendeciler marka sayılmıyor. Gözlenen aday kümesi: VPN 19, kozmetik 74, editors 30, hosting 36, travel 27 marka.

`top_recommendation` çözünürlüğü beş domainde **%99,2–100**. Anılma çözünürlüğü Türkçe VPN'de %99,8, kozmetikte %91,3; İngilizce'de %69–82 — kalan kısım bilerek elenen havayolu, framework ve yayın grubu.

Bölmeler ve testler

5 fold, `query_id` ile gruplu, kategori içinde dağıtılmış ve `data/processed/modeling/splits_*.json` altında donmuş. Türkçe'de domain başına 5 sorgu olduğu için 5 fold = leave-one-query-out.

15 yeni test yazıldı; suite **74/74** geçiyor. Testler arasında bir sorunun iki fold'a düşmemesi, prior'ların yalnız eğitim satırlarından hesaplanması, cevaptan türeyen hiçbir alanın özellik setinde olmaması ve batch sırası değişse bile skorların doğru satıra yazılması var.

Kullanılan veri, model ve araçlar

VERİ KAYNAKLARI

KORPUS	YANIT	TASARIM	ÜRETİM MODELLERİ
3RAIN/brand-bias-evaluations revision 400da04e · MIT	9.586	4 domain × 10 sorgu × 2 koşul × ~30 tekrar · T=0,7	claude-opus-4-6 · gpt-5.4 · grok-4.20-reasoning · zai-org/GLM-5
furkankarli/turkish-brand-bias-evaluations şema referansla birebir + language	300	2 domain × 5 sorgu × 2 koşul × 5 tekrar · T=0,7	gemini-3.5-flash-lite · MiniMax-M2.7 · abliterated-model-large-v2

Türkçe korpusun etiketleri Cerebras `gpt-oss-120b` ile çıkarıldı (sıcaklık 0, katı JSON şeması); arama sonuçları Serper Google Search API'den, Türkiye/Türkçe, sorgu başına 10 organik sonuç. **Hiçbir koşulda modele marka listesi verilmedi** — projenin üzerine kurulu olduğu kural bu, iki korpusta da korunuyor.

KURDUĞUMUZ MODEL AİLESİ

MODEL	ALGORİTMA / ARAÇ	GÖRDÜĞÜ BİLGİ	ROLÜ
naive · konum	Kural	İlk sıradaki arama sonucunun markası	Aşılması zorunlu taban
naive · sıklık	Kural	Eğitim fold'unda en sık kazanan marka	Aşılması zorunlu taban
M0	LogisticRegression scikit-learn 1.9	Yalnız marka prior'ı	Tanınırlık etkisini izole eder
M1	LogisticRegression	+ arama konumu, kaynak tipi (resmî/editoryal/affiliate/forum)	Yapısal yerleşim etkisi
M2	LGBMClassifier · 400 ağaç lightgbm 4.7 · SHAP: pred_contrib	+ snippet dil özellikleri (otorite, sosyal kanıt, ayrıntı, çekimserlik, üstünlük)	Üretim modeli — öneri üretebilen tek model
M3	Cross-encoder · 110M param bert-base-uncased (EN) dbmdz/bert-base-turkish-cased (TR) transformers 5.16 · torch 2.6+cu124	Sorgu + markayı anan snippet metni, ham hâlde	Maskeleme ablation'ını mümkün kılar

Dil sözlükleri iki dil için ayrı ayrı, sürümlü YAML olarak `configs/modeling/lexicons/` altında. M3 yerel RTX 3050'de fp16 ile eğitildi; 4 GB VRAM 250 bin kelimelik çok dilli bir kodlayıcıyı almadığı için her iki hatta da base boyutlu tek dilli BERT kullanıldı — bu aynı zamanda iki hattı mimari olarak karşılaştırılabilir tutuyor.

İki hedef modellendi

`y_top` — marka, yanıtın tek birincil önerisi mi. Concept note'un tanımladığı görev; yalnız karara bağlanmış yanıtlarda ölçülebiliyor.

`y_mention` — marka yanıtta anılıyor mu. Satır düzeyinde **AI Share of Voice**, yani projenin manşet KPI'ı. Yoğun sinyal olduğu için beş domainin hepsinde çalışıyor; kozmetik gibi kazananı belirsiz domainleri veri dışında bırakmamayı sağlıyor.

BULGU 1

Aramanın yön değiştirdiği yer


Her marka için iki nokta var: modelin yalnız kendi bilgisiyle konuştuğu koşul ve web'e bakabildiği koşul. Aradaki mesafe, aramanın o markaya ne yaptığıdır. İki panel de aynı yedi markayı, aynı ölçekte gösteriyor.

VPN markalarının anılma oranı, iki koşul arasında


Yanıtların yüzde kaçında marka adı geçiyor. Türkçe 150, İngilizce 2.388 VPN yanıtı.

● Arama kapalı ● Arama açık

TÜRKÇE · 3 MODEL · 150 YANIT



İNGİLİZCE · 4 MODEL · 2.388 YANIT



Mahremiyet itibarıyla tanınan markalar (Mullvad, IVPN) arama açıldığında görünürlük **kaybediyor**; ticari pazarlama yapan markalar (NordVPN, ExpressVPN, Surfshark) büyük kazanç sağlıyor. Modelin kendi belleğiyle önerdiği marka ile web'in ona gösterdiği marka farklı.

AYNI ÖRÜNTÜ İKİNCİ SEKTÖRDE • TÜRKÇE KOZMETİK • 150 YANIT

MARKA	KAPALI	AÇIK	FARK
L'Oréal Paris	%26,7	%45,3	+18,7
Bioderma	%33,3	%45,3	+12,0
Flormar yerel	%29,3	%36,0	+6,7
La Roche-Posay	%60,0	%64,0	+4,0
The Ordinary	%49,3	%36,0	-13,3
CeraVe	%65,3	%48,0	-17,3

Kozmetikte de aynı yapı: internet topluluklarının favorisi olan içerik odaklı markalar (CeraVe, The Ordinary) arama açılınca düşüyor, kitlesel pazarlama yapan markalar (L'Oréal Paris, Bioderma) yükseliyor. **Bulgu iki sektörde ve iki dilde tekrarlanıyor** — dört bağımsız gözlem.

Bu, projenin ölçmeye çalıştığı içerik etkisinin doğrudan kanıtı: asistanın gördüğü içerik değiştiğinde öneri de değişiyor. Aramalı koşulda öne çıkan markaların ortak özelliği, inceleme ve affiliate sitelerinin ekosisteminde baskın olmaları.

BULGU 2

Model ailesi, beş domainin tamamı

Modeller kümülatif kuruldu, çünkü anlamlı olan tek bir skor değil aralarındaki fark. Tüm skorlar fold-dışı. Kalın yazılan, o satırın kazananı.

HEDEF: BİRİNCİL ÖNERİ (Y_TOP) · PR-AUC

DOMAIN	NAİVE KONUM	NAİVE SIKLIK	M0 PRIOR	M1 +YAPI	M2 +DİL
İNGİLİZCE					
vpn	0,133	0,535	0,580	0,664	0,801
editors	0,112	0,802	0,830	0,862	0,838
travel	0,129	0,546	0,548	0,653	0,540
hosting	0,106	0,115	0,131	0,165	0,190
TÜRKÇE					
vpn	0,114	0,179	0,220	0,251	0,284
cosmetics	0,047	0,160	0,211	0,236	0,140

HEDEF: GÖRÜNÜRLÜK / ASOV (Y_MENTION) · PR-AUC

DOMAIN	NAİVE KONUM	NAİVE SIKLIK	M0 PRIOR	M1 +YAPI	M2 +DİL
İNGİLİZCE					
vpn	0,456	0,674	0,733	0,828	0,876
editors	0,391	0,488	0,652	0,694	0,734
travel	0,440	0,423	0,605	0,708	0,732
hosting	0,399	0,375	0,410	0,561	0,638
TÜRKÇE					
vpn	0,380	0,500	0,663	0,692	0,698
cosmetics	0,244	0,220	0,257	0,380	0,358

ASoV hedefinde M2 altı durumun dördünde kazanıyor ve her yerde naive tabanları belirgin biçimde geçiyor — projenin manşet KPI'ı için hat çalışıyor. Birincil öneri hedefinde tablo daha karışık: VPN ve hosting'de M2, editors ve travel'da M1, Türkçe kozmetikte yine M1 önde.

İngilizce VPN'de M2, "her zaman en sık kazananı söyle" temelini **+0,27 PR-AUC** geçiyor ve top-1 doğruluğu %64,1'den %72,4'e çıkıyor — concept note'un $\geq 0,60$ PR-AUC hedefi karşılandı. Buna karşılık **editors'ta hiçbir model temeli geçemiyor**: VS Code kararların %91'ini alıyor, top-1 dört modelde de 0,913. Kazanan-her-şeyi-alır bir kategoride tahmin edilecek bir şey yok.

Seviye farkı da bulgunun parçası. İngilizce'de Mullvad kararların %64'ünü aldığı için tanınırlık tek başına çok güçlü bir tahminci; Türkçe'de kazanan üç marka arasına dağıldığı için prior daha

az iş görüyor. İngilizce VPN önerileri kazanan-her-şeyi-alır, Türkçe pazarda alan var.

BULGU 3

Maskeleme: ne kadarı isim, ne kadarı içerik

M3 cross-encoder aynı satırlar ve aynı fold'lar üzerinde iki kez eğitildi. İkinci turda kayıttaki her marka adı — adayınki dahil — [BRAND] ile değiştirildi. İçerikteki iddialar, kanıtlar ve ayrıntı düzeyi yerinde kaldı; yalnız kimlik silindi. Bunu bir özellik modeli yapamaz, çünkü müdahale metnin kendisine.

Aynı snippet, iki hâli

ADLI

...En İyi VPN'ler **ExpressVPN**, harika hızlar, basit bir uygulama ve güçlü güvenlik özellikleri ile... **NordVPN**, **Surfshark** ve...

MASKELİ

...En İyi VPN'ler [BRAND], harika hızlar, basit bir uygulama ve güçlü güvenlik özellikleri ile... [BRAND], [BRAND] ve...

İNGİLİZCE VPN · ARAMALI YANITLAR · ÜÇ BAĞIMSIZ SEED · PR-AUC

SEED	M3 ADLI	M3 MASKELİ	FARK	TOP-1 ADLI	TOP-1 MASKELİ
42	0,758	0,376	0,382	0,728	0,486
7	0,639	0,354	0,285	0,681	0,474
13	0,744	0,357	0,387	0,757	0,443
Ortalama	0,714	0,362	0,351	0,722	0,468

İKİ DİL YAN YANA · AYNI SATIRLAR, AYNI FOLD'LAR · PR-AUC

MODEL	İNGİLİZCE 975 YANIT · 3 SEED ORT.	TÜRKÇE 57 YANIT · 5 KOŞU ORT.
M2 · LightGBM	0,693	0,260
M3 adlı	0,714	0,173
M3 maskeli	0,362	0,165
Maskeleme farkı	-0,351	-0,008
	%51 ayakta kalıyor hep aynı yönde: 0,285-0,387	ölçülemiyor işaret dönüyor

İngilizce'de marka adları silinince PR-AUC yarıya iniyor (0,714 → 0,362), top-1 doğruluğu %72,2'den %46,8'e düşüyor. Fark üç seed'in üçünde de büyük ve hep aynı

yönde; maskeli sonuç ayrıca çok kararlı (0,354–0,376). Marka kimliği, asistanın seçiminin *tahmin edilebilirliğinin* büyük kısmını taşıyor.

Bu deneyin göstermediği şey

Bu sonucu "kararın yarısı marka isminden geliyor" diye okumak, deneyin verdiği fazlasını söylemek olur. Üç sebep:

- **Ölçtüğümüz şey kendi modelimiz.** M3, asistanın çıktısını tahmin etmek için eğittiğimiz bir *vekil* model. Maskeleme bu vekilin neye dayandığını gösterir; asistanın içindeki mekanizmayı gözlemlemiyoruz.
- **Maskeleme yalnız ismi silmiyor.** Bir markanın *hangi* sayfalarda görüldüğü de kimlikle ilişkili bir örüntü ve o yerinde kalıyor. Ayrıca maskelendikten sonra model, aynı snippet'leri paylaşan adayları birbirinden ayırt edemez hâle geliyor — kaybın bir kısmı bundan da olabilir.
- **Metrikteki yarılanma, payın yarı yarıya bölünmesi demek değil.** PR-AUC düşüşünü "nedensel katkının yüzde kaç" diye çevirmenin doğrusal bir karşılığı yok. Bulgu ayrıca tek domain (VPN) ve tek koşul (aramalı) üzerinde.

Marka adları maskelendiğinde vekil modelin PR-AUC değeri 0,714'ten 0,362'ye düştü. Bu fark nedensel katkı yüzdesi, tanınırlık/içerik payına alt veya üst sınır ya da bütçe oranı olarak yorumlanamaz.

Türkçe'de aynı ölçüm hiç yapılamıyor. Beş bağımsız koşuda adlı ortalama 0,173, maskeli 0,165 — aradaki 0,008'lik fark, seed'ler arası ~0,08'lik yayılımın onda biri. Koşuların üçünde adlı, ikisinde maskeli önde çıktı. 57 karara bağlanmış yanıtla bu sorunun cevabı yok.

BULGU 4

Kararı ne sürüklüyor

M2'nin kararlarına katkısı LightGBM'in `pred_contrib` çıktısıyla, yani ağaçlar için kesin SHAP değerleriyle ölçtük. Ayrı bir `shap` paketi gerekmedi.

ORTALAMA | SHAP | · HEDEF: BİRİNCİL ÖNERİ

#	İNGİLİZCE	KATKI	TÜRKÇE	KATKI
1	prior_top_all	2,675	prior_top_all	1,725
2	prior_top_off	0,947	condition	0,894
3	model_id	0,447	model_id	0,855
4	condition	0,294	prior_top_off	0,631
5	prior_mention_all	0,266	prior_mention_all	0,606
6	prior_mention_off	0,130	prior_mention_off	0,181

İki dilde de **marka prior'ı açık ara baskın**; snippet dil özellikleri ilk altıya bile giremiyor. Maskeleme ablation'ı ile aynı yöne işaret ediyor — ama ikisi de aynı vekil modeller üzerinde ölçüldüğü için birbirinin bağımsız doğrulaması sayılmazlar. İkisinin ortak söylediği şey şu: **tanınırlık, tahmin edilebilirliğin baskın kaynağı; içeriğin katkısı ikincil ama sıfır değil.**

Pazarlama karşılığı — dikkatle: bir markanın görünmezliği hem "kimse seni tanımıyor" hem "senin hakkında yazılan içerik zayıf" sebebinden kaynaklanıyor ve bunlar zıt bütçe kararları (ilki çeyreklerle ölçülen marka yatırımı, ikincisi haftalar içinde düzeltilebilen içerik işi). Ayrımı yapabildiğimizi gösterdik; **ama elimizdeki rakamlar bir bütçe oranı vermiyor.** Ajansa "%50 şuraya, %50 buraya" demek için Layer B'nin kontrollü müdahale verisi gerekir ve o henüz toplanmadı.

— YAPILAN İŞ

Bugün düzeltilen yedi şey

Bunlar not olarak duruyor çünkü her biri ya bir sonucu değiştirdi ya da sessizce yanlış bir sonuç üretecekti.

SORUN	ETKİSİ	ÇÖZÜM
Sınıf oranı varsayımı yanlıştı	Concept note'un %12,5 oranı hiç uygulanmayan "8 adaylı liste" tasarımından geliyordu. Gerçek oran EN %3,6, TR %2,8.	Hedefler gerçek orana göre yeniden ifade edildi.
Türkçe küçük harf kuralı marka adlarını bozuyordu	Toplama hattı <code>IVPN</code> 'i <code>ivpn</code> 'e, <code>Private Internet Access</code> 'i <code>private internet access</code> 'e çevirmiş. İki dil aynı markayı farklı sanıyordu.	i-katlamalı karşılaştırma anahtarı; testle korunuyor.
NFKC, ™ işareti harfe çeviriyordu	<code>NordVPN™</code> anahtarı <code>nordvpntm</code> oluyordu, yani ayrı bir marka sayılıyordu. Test yakaladı.	Semboller normalizasyondan önce temizleniyor.
Cevaptan türeyen özellikler sızıntıydı	Yanıt uzunluğu, anılan marka sayısı, çekimserlik düzeyi — hepsi tahmin etmeye çalıştığımız cevabın içinden çıkıyor. Kılık değiştirmiş etiketler.	Özellik seti modelin cevabı üretmeden önce gördüğüyle sınırlandı; ihlal denemesi hata veriyor.
top-1 metriği anlamsız değer ürettiyordu	ASoV hedefinde yanıt başına 4–6 marka var; metrik tek kazananı olan az sayıda yanıtı ölçüp editors'ta 1,0, hosting'te 0,07 gibi manşet ürettiyordu.	Hedef tek kazanan tanımlamıyorsa metrik tanımsız döner.
M3 eğitimi 2,7 kat yavaş çalışıyordu	Satırların yarısı 29 token, bir kısmı 700+. Rastgele karışık batch'lerde 16'lık grupta uzun satır bulunma olasılığı %99, yani hemen her batch 192'ye doldurup boşluk işliyordu.	Uzunluğa göre gruplu batch'leme. Fold başına 7,9 → 2,9 dakika . Skorların doğru satıra yazıldığı testle korunuyor.
Rapor grafiği hiç çizilmiyordu	Script blogunda eksik parantez (sözdizimi hatası) ve SVG sunum özniteliklerinde <code>var()</code> kullanımı. Grafik bomboş yayınlanmıştı.	Sözdizimi düzeltildi, boyama CSS sınıflarına taşındı; ekran görüntüsüyle doğrulandı.

SINIRLILIK

Bu sonuçların söyleyemediği şeyler

- Dil ve model iç içe.** İngilizce korpus Claude/GPT/Grok/GLM ile, Türkçe korpus Gemini/MiniMax/Abliteration ile toplandı. Aradaki farkı saf dil etkisi olarak raporlayamayız — "EN korpusu vs TR korpusu" farkı olarak raporlarız. Arama etkisinin *yönü* dört bağımsız gözlemde aynı çıktığı için o bulgu bundan güçlü etkilenmiyor.
- Türkçe tarafı ince.** Domain başına 5 benzersiz sorgu var, yani gruplu çapraz doğrulama en fazla leave-one-query-out. Güven aralıkları geniş (M2 için 0,215–0,410) ve veri büyümedikçe öyle kalacak.
- M3, M2'yi PR-AUC'de güvenilir şekilde geçmiyor.** Üç seed ortalaması 0,714, M2 ise 0,693 — ve seed 7 tek başına 0,639 ile M2'nin altında kaldı. Güven aralıkları da örtüşüyor. Top-1'de tablo farklı: M3 üç seed'in üçünde de (0,681 / 0,728 / 0,757) M2'nin 0,626'sını geçiyor. Yani M3 doğru markayı ilk sıraya koymakta daha iyi, genel sıralama kalitesinde ayrışmıyor. **Üretim modeli M2 olarak kalıyor** — yorumlanabilir ve SHAP ile öneri üretebilen tek model o.
- Türkçe'de M3 hiç öğrenmiyor.** Ortalama 0,173 ile hem M2'nin (0,260) hem de naive sıklık temelini (0,168) seviyesinde; koşudan koşuya 0,124–0,202 arasında savruluyor. Fold başına

46 gradyan adımı düşüyor, İngilizce'de 828. Bunun veri azlığından mı yoksa yetersiz eğitimden mi kaynaklandığı henüz ayrıştırılmadı.

- **Tek koşuya güvenilmez.** Bunu kendi üzerimizde gördük: M3'ün ilk Türkçe koşusu maskelemenin PR-AUC'yi 0,031 düşürdüğünü söylüyordu. Yalnız batch sırasını değiştirip tekrarlayınca fark ters döndü. Bu ölçekte her M3 sonucu en az üç seed ile raporlanmalı.
- **TR kozmetikte birincil öneri tahmini kurulamıyor.** 150 yanıtta 194 farklı marka, yanıtların %72'sinde kazanan yok. Bu domain ASoV hedefiyle analizde kalıyor, top-1 tahmininde değil.
- **Layer B hiç toplanmadı.** Concept note'un kontrollü müdahale katmanı (30 marka × 8 açıklama varyantı) yok. Dolayısıyla içerik etkisi gözlemsel; nedensel iddia yalnız maskeleme ablation'ının verdiği kadar.
- **Affiliate etiketleme kural tabanlı.** Concept note iki bağımsız annotatörle etiketleme öngörüyordu; şu an alan adı listeleri elle yazılmış kurallar. İnsan etiketlemesi yapılmadı, uyum oranı raporlanamıyor.

YÖNTEM

Sızıntıya karşı alınan önlemler

Bu tasarımda skorları şişirmenin üç kolay yolu var; üçü de kapatıldı ve testle korunuyor.

- **Tekrarlar bölünmüyor.** Her hücre aynı sorguyu 0,7 sıcaklıkta 30 kez tekrarlıyor. Satır düzeyinde rastgele bölme, neredeyse aynı yanıtları bölmenin iki yakasına koyardı. Fold'lar `query_id` ile atanıyor, donduruluyor ve bir sorgunun iki fold'a düşmediği testle doğrulanıyor.
- **Prior'lar fold içinde.** Tüm veriden hesaplanmış bir marka prior'ı, ayrılmış sorguların kendi sonuçlarını eğitime geri taşırdı. Her prior yalnız o fold'un eğitim parçasından, kategori taban oranına doğru yumuşatılarak hesaplanıyor.
- **Cevaptan türeyen özellik yok.** Özellik seti modelin cevabı üretmeden önce gördüğü şeyle sınırlı: marka prior'ı, getirilen içerik ve koşul/model/kategori.

Aday kümesi de etiketten türetilmiyor: beş domain için küratörlü marka kaydı YAML olarak yayında, yalnızca korpusta bir kez bile görünen markalarla sınırlanıyor.

YÖNTEM

Yeniden üretme

Temiz bir klondan bu rapordaki her sayı sırayla şu komutlarla üretiliyor. Veri dosyaları Git'e girmiyor; kod ve raporlar paylaşılıyor.

```
make setup          # Python 3.11 + uv, kancalar
make reference-data  # İngilizce referansı sabit sürümden indir
uv run pytest        # 74 test
```

```
uv run python scripts/run_family.py      # pair'ler, fold'lar, M0-M2, iki hedef
uv run python scripts/score_tables.py    # metrik tabloları (yeniden eğitmeden)
uv run python scripts/run_m3.py          # M3 + maskeleme, iki dil
uv run python scripts/compare_tracks.py  # VPN yan yana tablosu
uv run python scripts/attribution.py      # SHAP + ASoV temeli
uv run python scripts/build_pdf.py       # bu raporun PDF'i
```

DURUM

Nerede kaldık

BİTTİ

Veri seti. İngilizce referans sabit sürüme pinli ve doğrulanmış; Türkçe 300 yanıt HuggingFace'te yayında, şema referansla birebir. Bu adım kapandı.

BİTTİ

Modellemeye hazır veri. 282.450 aday çifti, donmuş gruplu fold'lar, küratörlü marka kaydı, sızıntı testleri geçiyor.

BİTTİ

Temel ve M0–M2. İki naive temel, üç kümülatif model, beş domain, iki hedef; SHAP atfı çıkarıldı.

BİTTİ

M3 ve maskeleme ablation'ı. İki dilde adlı ve maskeli varyantlar, M0–M2 ile aynı fold'larda. İngilizce'de fark ölçülebilir ve büyük; Türkçe'de veri yetmiyor.

BİTTİ

Türkçe görünürlük temeli. ASoV tablosu iki koşul için, iki domainde, 93 marka.

BİTTİ

İngilizce ablation'ın seed tekrarı. Üç seed tamamlandı, fark üçünde de aynı yönde ve büyük (0,285–0,387). Tekrar, M3'ün M2'ye üstünlüğü hakkındaki ilk iddiayı da düzeltti: tek seed 0,758 diyordu, üç seed ortalaması 0,714 ve M2 ile ayrışmıyor.

KARAR

Türkçe veri genişletilecek mi. Ekip kararı bekliyor. Kritik nokta: istatistiksel birim yanıt değil sorgu — tekrar sayısını artırmak güven aralıklarını daraltmaz, sorgu sayısını artırmak daraltır. Ayrı bir karar notu hazırlandı.

SIRADA

Streamlit arayüzü ve etik filtre (M7). Marka + sektör girdisinden rapor üreten prototip; uydurma otorite önerilerini kod düzeyinde engelleyen, birim testli filtre.

SIRADA

Ajans doğrulaması (M8). Gerçek bir marka için rapor üretip uygulanabilirlik değerlendirmesi almak.

Kaynaklar: **3RAIN/brand-bias-evaluations** (revision 400da04e, MIT) · **furkankarli/turkish-brand-bias-evaluations**

Tüm skorlar fold-dışı. Güven aralıkları sorgu kümesinde 400 tekrarlı bootstrap ile. Marka kayıtları ve sözlükler `configs/modeling/` altında sürümlü. M3 rakamları bağımsız koşuların ortalaması: İngilizce üç seed, Türkçe beş koşu.